0

Ульянин Дмитрий 597

1. Вступление

https://towardsdatascience.com/anime-recommendation-engine-from-matrix-factorization-to-learning-to-rank-845d4a9af335 (https://towardsdatascience.com/anime-recommendation-engine-from-matrix-factorization-to-learning-to-rank-845d4a9af335)

В статье обсуждается какие бывают алгоритмы, чтобы сделать какой-то движок для рекоммендаций.

Задача рекоммендаций:

Есть набор юзеров u, пронумерованных $1..n$, набор итемов i (в данном случае, аниме), пронумерованных $1..m$

Необходимо для юзера уметь получать какой-то топ итемов, которые ему **могут быть интересны**

2 Data Pre-processing and Exploration и мое замечение

> There are over 30M observations, 100K users and 6K animation movies in this data set

Из этого можно сделать вывод, что матрица $r_{i,j}$ = оценка юзера i аниме j, имеющая размер $100 \cdot 6 \cdot 10^3 \cdot 10^3 = 600 \cdot 10^6$ -- довольно разряженная, то есть сигнал не очень плотный

(на самом деле это важно, дает много проблем при простроении системы -- алгоритмы не сходятся, матрица плохо обусловлена и т.п.)

3 Коллаборативная фильтрация

Что-то вроде определения На основе предпочтений других юзеров прогнозировать неизвестные оценки данного юзера

В статье говорится, что очень распространенный способ -- представить пользователей и итемы в качестве эмбеддингов p_u, q_i таким образом, что оценка $\hat{r}_{u,i} =< p_u, q_i >$ (скалярное произведение)

note:

На самом деле, это довольно грубо, обычно действуют в предположениях, что у итема и юзера есть еще какие-то смещения, а оценку предстввляют как $\hat{r}_{u,i} =< p_u, q_i > +\mu + b_i + b_u$

μ -- общее смещение оценок, b_i b_u -- индивидуальные смещения пользователей и предметов

Кажется, это называется Normalization of Global Effects

3.1 Факторизация матриц

Матрица r представляется как факторизация двух матриц U и P.

Таким образом $\hat{r}_{u,i}$ равна произведению строки строки $U_{u,*}$ на столбец $P_{*,i}$. То есть мы каждому юзеру и итему сопоставляется эмбеддинг -- строка и столбец соответствующей матрицы, а оценка -- их скалярное произведеие

3.1.1 Alternating Least Squares(ALS)

ALS -- это matrix factorisation, осноывнный на линале:

Используем линал (я просто приведу цитату из статьи https://habr.com/company/yandex/blog/241455/ (https://habr.com/company/yandex/blog/241455/) от Мишы Ройзнера)

> Функционал, который мы пытаемся оптимизировать — сумма квадратов ошибок плюс сумма квадратов всех параметров — это тоже квадратичный функционал, он очень похож на параболу.

> Для каждого конкретного параметра, если мы зафиксируем все остальные, это будет как раз параболой. Т.е. минимум по одной координате мы можем точно определить.

> На этом соображении и основан метод Alternating Least Squares. В итогн мы попеременно точно находим минимумы то по одним координатам, то по другим:

$$\boldsymbol{p}_u^*(\Theta) = \arg\min_{\boldsymbol{p}_u} J(\Theta) = (\boldsymbol{Q}_u^T\boldsymbol{Q}_u + \lambda\boldsymbol{I})^{-1}\boldsymbol{Q}_u^T\boldsymbol{r}_u,$$

$$\boldsymbol{q}_i^*(\Theta) = \arg\min_{\boldsymbol{q}_i} J(\Theta) = (\boldsymbol{P}_i^T\boldsymbol{P}_i + \lambda\boldsymbol{I})^{-1}\boldsymbol{P}_i^T\boldsymbol{r}_i.$$

Мы фиксируем все параметры объектов, оптимизируем точно параметры пользователей, дальше фиксируем параметры пользователей и оптимизируем параметры объектов. Действуем итеративно:

$$\forall u \in U \quad \boldsymbol{p}_u^{2t+1} = \boldsymbol{p}_u^*(\Theta_{2t}),$$

$$\forall i \in I \quad \boldsymbol{q}_i^{2t+2} = \boldsymbol{q}_i^*(\Theta_{2t+1}).$$

Юзалась либа pyspark.mllib.recommendation.ALS

3.1.2 SVD (Singular Value Decomposition)

Это все тот же matrix factorization, но уже юзаем метопты, а именно градиентный спуск (stochastic gradient descent)

Юзалась либа surprise

3.2 Neural Networks

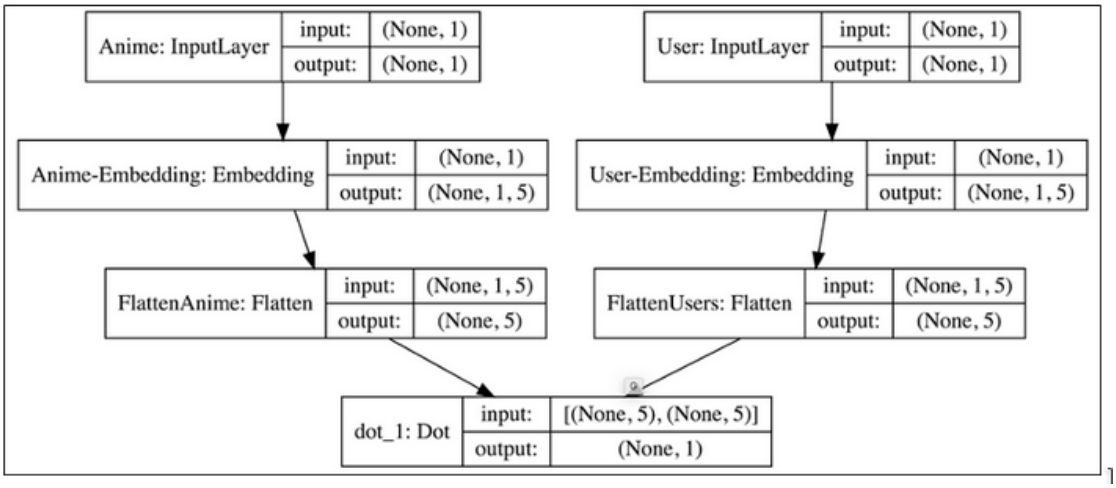

target -- $r_{u,i}$, нейросетка состоит из двух частей, двух слоев.

Вход -- сигналы юзер и item.

Можно условно сказать, что аервый слой учит по эмбеддинги юзеров и item'ов, второй их сворачивает

Таким образом опять же получили два эмбеда, скалярное произведение которых дает оценку

4. Обучение ранжированию

Все предыдущие вещи сами по себе не очень жгут и обычно используются просто как майнеры кандидатов при обучении ранжированию.

Почему?

В статье сказано следующее:

Представьте, у нас есть два итема с оценками 3, 4. Один алгоритм дал оценки 2, 5, а другой -- 4. 3.

С точки зрения MSE алгоритмы одинаково хороши, однако, понятно, что один из алгоритмом переупорядочил результаты, что не очень хорошо.

Дальше в статье просто рассматривались разные метрики и способы построение оценок для этой задачи

4.1 Eigen Rank

Здесь метрика не нужна, алгоритм сразу выдает ранжирование

Тут ранжирование строится на том, что у нас уже есть какой-то список ближайшие соседей для ющера -- N_u

Дальше, для каждой пары соседей i, j строится preference function (функция предпочтения) $\psi(i, j)$. Затем, все соседи ранжируются жадным алгоритмом на основе $\psi(i, j)$

$$\Psi(i,j) = \frac{\sum\limits_{v \in N_u^{i,j}} s_{u,v} \cdot (r_{v,i} - r_{v,j})}{\sum\limits_{v \in N_u^{i,j}} s_{u,v}}$$

]

:
```
def Neighb(user_id, rating, cutoff = 10):
    all_users = list((rating['user_id']).unique())#.remove(user_id)
    all_users.remove(user_id)
    neighb_score = {}
    for u in all_users:
        print("user no: ", u)
        neighb_score[u] = Kendall_CC(user_id, u, rating)
    top_10 = sorted(neighb_score.items(), key=operator.itemgetter(1), reverse=True)[:cutoff]
    return dict(top_10)
```

Жадник:

```
def calculate_order_greedy(Item_list, rating, user_id):
    pie = {}
    rank = {}
    for i in Item_list:
        print("item is: ", i)
        pie[i] = preference_func(i, i+1, user_id, rating) - preference_func(i+1, i, user_id, rating)
    while (len(Item_list) > 0):
        t = max(pie.items(), key = operator.itemgetter(1))[0]
        rank[t] = len(Item_list)
        Item_list.remove(t)
        for k in Item_list:
            pie[k] = pie[k] + preference_func(t,k, user_id, rating) - preference_func(k,t, user_id, r
ating)
    return rank
```

4.2 LambdaMART

Оценку строим с помощью градиентного бустинга на решающих деревьях. Признаки в деревьях -- popularity, duration, genres, number of times particular user has watched, release year, ...

Дальше нужна метрика

4.3 Метрики

4.3.1 NDCG-Normalized Discounted Cumulative Gain

Предподагаем, что существует идеальное ранжирование (его строим на основе имеющихся рейтингов). А также, что очень релевантные документы (vital) являются более полезными, чем низкорелевантные документы (relevant-).

$$\mathrm{NDCG}(Q,k) = \frac{1}{|Q|}\sum_{u\in Q} Z_u \sum_{p=1}^{k} \frac{2^{R(u,p)}-1}{\log(1+p)}$$

Fig: Zu is the Normalization factor (inverse of Ideal NDCG), Q represents all the users and R(u,p) is the rating given by user u to anime at rank p

В итоге, NDCG@K -- NDCG, вычисленное для топ K рекоммендаций по нашему движку

4.3.2 MAP -- Mean Average Precision

(почитал так же статью https://habr.com/company/econtenta/blog/303458/ (https://habr.com/company/econtenta/blog/303458/))

Пусть AP@K (average precision at K) = $\frac{1}{K} \cdot \sum_{i=1}^{K} r(i) \cdot p@i$,

где $r(i)$ -- оценка топ i-го элемента, $p@i$ -- количество релевантных документов среди первых i

Идея map@K заключается в том, чтобы посчитать ap@K для каждого объекта и усреднить:

Тогда Mean average precision at K (map@K) = $\frac{1}{N} \cdot \sum_{i=1}^{K} ap@K_i$

> Замечание: идея эта вполне логична, если предположить, что все пользователи одинаково нужны и одинаково важны. Если же это не так, то вместо простого усреднения можно использовать взвешенное, домножив ap@K каждого объекта на соответствующий его «важности» вес.

Заключение

Учитывая, что написано у этих ребят в TODO -- это лишь общие идеи, на чем могут базироваться рекоммендаци и не панацея. В кажом конкретном случае может <<жечь>> что-то свое, в зависимости от специфики области

А с runtime так вообще все плохо -- на python там не попишешь и предсказывать надо за 400 мс, а не за несколько часов

In [ ]: